



UNIVERSIDAD
SERGIO ARBOLEDA

Sistema híbrido LLM-agente para detección y verificación de desinformación financiera en Colombia

WILMAR ANDREY PACHON ADAMES

UNIVERSIDAD SERGIO ARBOLEDA
ESCUELA DE CIENCIAS EXACTAS E INGENIERÍA
BOGOTÁ D.C.
2026

Sistema híbrido LLM-agente para detección y verificación de desinformación financiera en Colombia

WILMAR ANDREY PACHON ADAMES

ANTEPROYECTO DE MAESTRÍA

Asesor
Juan Pablo Ospina

UNIVERSIDAD SERGIO ARBOLEDA
ESCUELA DE CIENCIAS EXACTAS E INGENIERÍA
MAESTRÍA EN INTELIGENCIA ARTIFICIAL
BOGOTÁ D.C.
2026

Contenido

Lista de figuras	5
Lista de tablas	7
1. Introducción	13
2. Estado del Arte	15
1. Marco teórico	15
1.1. Desinformación y verificación de hechos	15
1.2. Modelos de lenguaje de gran escala (LLMs)	15
1.3. Agentes inteligentes y el framework ReAct	16
2. Marco tecnológico	16
2.1. LangGraph como orquestador	16
2.2. Técnicas de prompting para clasificación	16
3. Antecedentes científicos	16
3.1. Sistemas multi-agente para verificación de hechos	16
3.2. Detección de noticias falsas en español	17
3.3. Contexto latinoamericano	18
3. Problema de investigación	19
1. Antecedentes del problema	19
2. Formulación del problema	19
3. Pregunta de investigación	20
4. Justificación	21
1. Justificación científica	21
2. Justificación práctica	21
3. Justificación social	21
4. Alcance	22
5. Objetivos	23
1. Objetivo general	23
2. Objetivos específicos	23
6. Metodología	25
1. Aspectos principales de la metodología	25
2. Método de investigación	25

Contenido

2.1.	Datos	25
3.	Proceso metodológico	26
3.1.	Fase 1: Construcción del benchmark (Junio–Julio 2026)	26
3.2.	Fase 2: Evaluación del LLM como clasificador (Agosto–Septiembre 2026)	27
3.3.	Fase 3: Implementación del agente verificador (Octubre–Noviembre 2026)	27
3.4.	Fase 4: Evaluación comparativa y redacción (Diciembre 2026–Enero 2027)	28
7.	Cronograma	29
8.	Presupuesto	31
9.	Resultados esperados	33
1.	Generación de Nuevo Conocimiento	33
2.	Fortalecimiento de la capacidad científica nacional	34
3.	Apropiación social del conocimiento	34
4.	Diagrama de arquitectura del sistema	35
5.	Listado de fuentes institucionales del agente	35
10.	Bibliografía	37

Lista de figuras

Lista de tablas

7.1. Cronograma de actividades del proyecto	29
8.1. Presupuesto general del proyecto	31
9.1. Resultados o productos esperados de nuevo conocimiento.	33



Glosario

AGENTE INTELIGENTE: entidad de software capaz de percibir su entorno, razonar sobre la información disponible y ejecutar acciones autónomas para alcanzar un objetivo definido, utilizando herramientas externas cuando es necesario.

CHAIN-OF-THOUGHT (CoT): técnica de prompting que solicita al modelo de lenguaje descomponer su razonamiento en pasos intermedios explícitos antes de emitir una respuesta final.

DESINFORMACIÓN: información falsa o engañosa creada y difundida deliberadamente con el propósito de causar daño o confundir a la audiencia.

FACT-CHECKING: proceso de verificación de hechos que consiste en evaluar la veracidad de afirmaciones, noticias o declaraciones mediante la consulta de fuentes primarias y evidencia verificable.

FEW-SHOT PROMPTING: técnica en la que se proporcionan al modelo de lenguaje un número reducido de ejemplos (típicamente entre 3 y 5) de la tarea deseada antes de presentarle la instancia a resolver.

IFCN: International Fact-Checking Network, red internacional que certifica organizaciones de verificación de hechos bajo principios de transparencia, imparcialidad y metodología rigurosa.

LANGGRAPH: biblioteca de orquestación de agentes basada en grafos de estados que permite definir flujos de decisión complejos con nodos condicionales y herramientas externas.

LLM: Large Language Model o modelo de lenguaje de gran escala. Modelo de inteligencia artificial entrenado sobre grandes volúmenes de texto capaz de comprender y generar lenguaje natural.

PROMPTING: técnica de interacción con modelos de lenguaje mediante instrucciones en lenguaje natural que definen la tarea, el contexto, el formato de salida y las restricciones del proceso.

REACT: framework propuesto por Yao et al. (2022) que combina razonamiento (Reasoning) y acción (Acting) en modelos de lenguaje, permitiendo que el modelo ge-

nere trazas de pensamiento intercaladas con acciones sobre herramientas externas.

ZERO-SHOT: configuración en la que el modelo de lenguaje recibe únicamente la instrucción de la tarea sin ejemplos previos, dependiendo exclusivamente de su conocimiento preentrenado.

Resumen

La desinformación financiera en Colombia constituye una amenaza creciente que afecta la estabilidad del sistema financiero y la toma de decisiones de millones de ciudadanos. Según datos de Activa Research y WIN (2022), el 53 % de los colombianos enfrenta noticias falsas diariamente, mientras que el Foro Económico Mundial clasificó la desinformación como el riesgo global número uno a corto plazo en su informe de 2024. En el dominio financiero, esta problemática se manifiesta en rumores sobre quiebras bancarias, fraudes disfrazados de noticias institucionales y datos falsos sobre tasas de interés.

El presente proyecto propone el diseño, implementación y evaluación de un sistema híbrido que combina modelos de lenguaje de gran escala (LLMs) con un agente verificador de fuentes institucionales colombianas para la detección automatizada de desinformación financiera. El sistema opera en dos niveles: primero, un LLM clasifica la noticia en tres categorías (verdadera, dudosa o falsa) mediante prompting especializado; segundo, cuando el modelo presenta baja confianza en su clasificación (umbral inferior a 0.80), un agente inteligente basado en el framework ReAct consulta automáticamente fuentes como la Superintendencia Financiera de Colombia, el Banco de la República, el DANE y ColombiaCheck para emitir un veredicto fundamentado y trazable.

La investigación incluye la construcción del primer benchmark de evaluación de desinformación financiera colombiana (800–1.000 noticias etiquetadas), la comparación sistemática de múltiples LLMs en configuraciones zero-shot, few-shot y chain-of-thought, y la evaluación del impacto del agente validador sobre la precisión y explicabilidad del sistema. El proyecto se desarrolla en un periodo de ocho meses y se ejecuta sobre infraestructura accesible (Google Colab y APIs comerciales).

Palabras clave: desinformación financiera, modelos de lenguaje, agentes inteligentes, verificación de hechos, Colombia, procesamiento de lenguaje natural.

Introducción

La proliferación de información falsa en medios digitales se ha convertido en uno de los desafíos más apremiantes de la sociedad contemporánea. En el contexto de América Latina, y particularmente en Colombia, la desinformación sobre el sistema financiero genera consecuencias económicas directas: rumores sobre quiebras bancarias provocan retiros masivos, noticias falsas sobre congelamiento de cuentas generan pánico financiero, y fraudes disfrazados de comunicados oficiales causan pérdidas patrimoniales a ciudadanos vulnerables.

A pesar de la gravedad del problema, las herramientas actuales de detección de desinformación presentan dos limitaciones fundamentales. Primero, la gran mayoría de los datasets existentes para detección de noticias falsas están en inglés [Oshikawa et al., 2020]. Segundo, los enfoques basados exclusivamente en modelos de lenguaje de gran escala (LLMs) alcanzan precisiones de apenas 64–71 % en tareas de verificación de hechos [Hoes et al., 2024], lo que resulta insuficiente para dominios donde los errores tienen consecuencias económicas reales.

El presente anteproyecto propone un sistema híbrido que aborda ambas limitaciones. El sistema combina la capacidad de clasificación de LLMs con un agente inteligente que consulta fuentes institucionales del ecosistema financiero colombiano (Superintendencia Financiera, Banco de la República, DANE, ColombiaCheck) cuando el modelo tiene baja confianza en su predicción. Esta arquitectura de activación condicional permite optimizar recursos computacionales al mismo tiempo que mejora la precisión y, fundamentalmente, la explicabilidad del sistema: cada veredicto incluye las fuentes consultadas y el razonamiento seguido por el agente.

El proyecto contempla tres contribuciones principales: (1) la construcción del primer benchmark de evaluación de desinformación financiera colombiana, (2) una arquitectura con umbral de confianza como detonador de un agente secundario de verificación, y (3) herramientas de consulta específicas para el ecosistema regulatorio financiero colombiano que no existen en la literatura actual.

El documento se organiza de la siguiente manera: el Capítulo 2 presenta el estado del arte en detección de desinformación y sistemas multi-agente; el Capítulo 3 formula el problema de investigación; el Capítulo 4 justifica la pertinencia del proyecto; el Capítulo 5 define los objetivos; el Capítulo 6 detalla la metodología; el Capítulo 7 presenta el cronograma; el Capítulo 8 estima el presupuesto; y el Capítulo 9 describe los resultados esperados.





UNIVERSIDAD
SERGIO ARBOLEDA

Estado del Arte

El presente capítulo desarrolla el marco referencial del proyecto, abordando los fundamentos teóricos, el contexto tecnológico y los antecedentes científicos relevantes, organizados de lo general a lo específico.

1. Marco teórico

1.1. Desinformación y verificación de hechos

La desinformación se define como información falsa o engañosa creada y difundida deliberadamente con el propósito de causar daño o confundir [Lazer et al., 2018]. Vosoughi, Roy y Aral [Vosoughi et al., 2018] demostraron mediante el análisis de 126.000 historias de noticias que la información falsa se propaga aproximadamente seis veces más rápido que la verdadera en redes sociales, un hallazgo que subraya la urgencia de desarrollar mecanismos automatizados de detección.

La verificación de hechos (*fact-checking*) es el proceso de evaluar la veracidad de afirmaciones mediante la consulta de fuentes primarias y evidencia verificable. La International Fact-Checking Network (IFCN) certifica organizaciones que cumplen con principios de transparencia, imparcialidad y metodología rigurosa. En Colombia, ColombiaCheck opera como el principal verificador certificado por la IFCN desde 2016.

1.2. Modelos de lenguaje de gran escala (LLMs)

Los modelos de lenguaje de gran escala son sistemas de inteligencia artificial entrenados sobre grandes volúmenes de texto que pueden comprender y generar lenguaje natural. Modelos como GPT-4 [OpenAI, 2023], Gemini [Google DeepMind, 2024] y Llama 3 [Meta AI, 2024] han demostrado capacidades notables en tareas de clasificación, razonamiento y generación de texto.

Sin embargo, evaluaciones recientes han demostrado que los LLMs utilizados de forma independiente presentan limitaciones significativas en tareas de verificación de hechos. Hoes et al. [Hoes et al., 2024] evaluaron el desempeño de GPT-3.5, GPT-4, Google Bard y Bing AI en la clasificación de afirmaciones verificadas por PolitiFact, obteniendo precisiones entre 64 % y 71 %. Estos resultados sugieren que los LLMs por sí solos no son suficientes para verificación de hechos confiable, particularmente en dominios especializados.

1.3. Agentes inteligentes y el framework ReAct

Yao et al. [Yao et al., 2023] propusieron ReAct (*Reasoning and Acting*), un framework que permite a los LLMs generar trazas de razonamiento intercaladas con acciones sobre herramientas externas. En ReAct, el modelo alterna entre pasos de “pensamiento” (donde planifica y razona) y pasos de “acción” (donde consulta bases de datos, APIs o motores de búsqueda). Este enfoque fue evaluado en benchmarks como HotPotQA y FEVER, demostrando mejoras significativas sobre métodos que solo razonan o solo actúan. ReAct constituye la base teórica del agente validador propuesto en este proyecto.

2. Marco tecnológico

2.1. LangGraph como orquestador

LangGraph es una biblioteca de orquestación de agentes desarrollada por LangChain que permite definir flujos de trabajo basados en grafos de estados. Cada nodo del grafo representa una operación (clasificación, decisión, consulta de fuentes) y las aristas definen las transiciones condicionales entre ellos. Esta arquitectura es particularmente adecuada para el sistema propuesto, donde la activación del agente validador depende del nivel de confianza del clasificador.

2.2. Técnicas de prompting para clasificación

La clasificación mediante LLMs puede realizarse en múltiples configuraciones [Brown et al., 2020]: (a) *zero-shot*, donde el modelo recibe únicamente la instrucción sin ejemplos; (b) *few-shot*, donde se proporcionan entre 3 y 5 ejemplos de cada clase; y (c) *chain-of-thought* [Wei et al., 2022], donde se solicita al modelo que descomponga su razonamiento en pasos explícitos. La comparación sistemática de estas configuraciones para el dominio financiero colombiano constituye uno de los aportes experimentales de este proyecto.

3. Antecedentes científicos

3.1. Sistemas multi-agente para verificación de hechos

La investigación reciente ha demostrado que los sistemas multi-agente superan consistentemente a los enfoques de un solo componente en tareas de verificación de hechos. A continuación se presentan los referentes más relevantes, organizados cronológicamente.

Li, Zhang y Malthouse [Li et al., 2024] propusieron **FactAgent**, un enfoque agéntico para detección de noticias falsas presentado en la European Conference on Artificial Intelligence (ECAI 2024). FactAgent emula el comportamiento de verificadores humanos

mediante un flujo de trabajo estructurado donde el LLM integra conocimiento interno y herramientas externas en subpasos especializados. El sistema opera sin datos de entrenamiento anotados (*zero-shot*) y genera explicaciones transparentes en cada paso, lo que lo hace altamente adaptable a dominios específicos.

Wu et al. [Wu2,] desarrollaron **MACAW**, un framework multi-agente con tres agentes especializados (Retrieval, Detective y Analyst) para validación cruzada de evidencia a múltiples granularidades. MACAW indexa conocimiento externo y extrae información a diferentes niveles de detalle para evaluar la integridad contextual de afirmaciones. Esta arquitectura de agentes especializados por función es la más cercana al sistema propuesto en este proyecto.

Kolli et al. [Kolli et al., 2025] propusieron un **sistema híbrido** que integra grafos de conocimiento (Wikidata, DBpedia), LLMs y agentes de búsqueda web para verificación de hechos. El sistema utiliza un mecanismo de activación por *fallback*: cuando el componente basado en grafos de conocimiento retorna “insuficiente información”, se activa automáticamente el módulo de búsqueda web con reescritura de afirmaciones. Reportaron F1 de 0,78 en el benchmark FEVER y 0,77 en FactKG. Este trabajo valida directamente la arquitectura de activación condicional propuesta en este proyecto.

Trinh, Nguyen y Hy [Trinh et al., 2025] presentaron un **sistema multi-agente con cuatro agentes especializados**: Input Ingestion (descomposición de afirmaciones), Query Generation (formulación de subconsultas), Evidence Retrieval (recuperación de evidencia verificable) y Verdict Prediction (síntesis de veredictos con explicaciones interpretables). Evaluado en FEVEROUS, HOVER y SciFact, el sistema logró una mejora del 12,3 % en Macro F1 sobre métodos de referencia. El código fuente está disponible públicamente.

Xiong et al. [Xiong et al., 2025] propusieron **DelphiAgent**, un framework multi-agente de verificación confiable publicado en *Information Processing & Management*. DelphiAgent enfatiza la generación de justificaciones trazables a lo largo del flujo de verificación, reforzando el argumento de que los sistemas multi-agente mejoran no solo la precisión sino también la confiabilidad del proceso.

3.2. Detección de noticias falsas en español

Los recursos para detección de noticias falsas en español son significativamente más limitados que los disponibles en inglés. Cañete et al. [Cañete et al., 2020] desarrollaron BETO, un modelo transformer preentrenado exclusivamente en texto en español, que ha sido utilizado exitosamente en tareas de clasificación de texto. Sánchez Gálvez et al. [Sánchez Gálvez et al., 2024] reportaron 98 % de exactitud utilizando BETO para detección de noticias falsas en español mexicano, utilizando aproximadamente 40.000 titulares de las cuentas de Twitter de Reforma y El Deforma.

Conneau et al. [Conneau et al., 2020] propusieron XLM-RoBERTa, un modelo multilingüe entrenado en 100 idiomas que permite comparaciones *cross-lingual* y ha sido utilizado en benchmarks de clasificación de texto en español.

3.3. Contexto latinoamericano

Un estudio publicado en *Nature* en 2025 [[Investigadores varios, 2025](#)] analizó por primera vez los factores que explican la diseminación y el control de noticias falsas en América Latina, utilizando datos del Latinobarómetro 2023 para Argentina, Brasil, Chile, Colombia, México y Perú. Los autores confirman que las contribuciones científicas previas provenían predominantemente del Norte Global, validando la brecha de investigación que este proyecto busca abordar.

Activa Research y WIN [[Activa Research and WIN International, 2022](#)] condujeron un estudio con 6.049 participantes en ocho países latinoamericanos, encontrando que el 53 % de los colombianos está expuesto diariamente a desinformación y que el 80 % de los latinoamericanos considera la desinformación una amenaza para la democracia.



Problema de investigación

1. Antecedentes del problema

La desinformación sobre el sistema financiero colombiano se manifiesta en múltiples formas: rumores virales sobre quiebras de entidades bancarias, noticias falsas sobre congelamiento de cuentas por reformas tributarias, fraudes presentados como comunicados oficiales del Banco de la República, y datos fabricados sobre tasas de interés y créditos hipotecarios. Este tipo de contenido circula principalmente a través de redes sociales y servicios de mensajería instantánea, donde la velocidad de propagación supera ampliamente la capacidad de respuesta de los verificadores humanos.

Los datos respaldan la magnitud del problema. El estudio de Activa Research y WIN (2022) reveló que el 53 % de los colombianos enfrenta noticias falsas todos o casi todos los días. El Foro Económico Mundial clasificó la desinformación como el riesgo global número uno a corto plazo en su Informe de Riesgos Globales 2024 [World Economic Forum, 2024]. Y la investigación seminal de Vosoughi et al. (2018) demostró que las noticias falsas se propagan seis veces más rápido que las verdaderas en plataformas digitales [Vosoughi et al., 2018].

2. Formulación del problema

El problema central que aborda esta investigación es la ausencia de herramientas automatizadas de verificación de noticias adaptadas al dominio financiero colombiano. Esta ausencia se compone de tres dimensiones:

Dimensión lingüística y cultural. El 81,5 % de los datasets existentes para detección de noticias falsas están en inglés [Oshikawa et al., 2020]. Los recursos en español son limitados y no cubren las particularidades del lenguaje financiero colombiano, que incluye terminología regulatoria específica (Superintendencia Financiera, circulares, PUC) y jerga bancaria local.

Dimensión técnica. Los modelos de lenguaje de gran escala (LLMs) utilizados de forma independiente alcanzan precisiones de apenas 64–71 % en tareas de verificación de hechos [Hoes et al., 2024]. Estos modelos no consultan fuentes externas, no verifican la existencia de las entidades citadas y no pueden acceder a información actualizada del ecosistema regulatorio colombiano.

Dimensión institucional. No existe ningún sistema automatizado que integre fuentes institucionales colombianas (Superintendencia Financiera, Banco de la República, DANE) como herramientas de verificación. Los fact-checkers humanos como Colom-

3. Pregunta de investigación

biaCheck realizan esta labor manualmente, lo que limita su capacidad de respuesta ante el volumen creciente de desinformación.

3. Pregunta de investigación

¿Puede un sistema híbrido que combina clasificación mediante modelos de lenguaje de gran escala con agentes de verificación de fuentes institucionales detectar desinformación sobre el sistema financiero colombiano con mayor precisión y explicabilidad que modelos de lenguaje utilizados de manera independiente?

Justificación

1. Justificación científica

La literatura reciente ha demostrado que los sistemas multi-agente superan consistentemente a los enfoques de un solo componente en tareas de verificación de hechos. FactAgent [Li et al., 2024] demostró la viabilidad de agentes adaptativos a dominios específicos. MACAW [Wu2,] probó que la especialización de agentes por función mejora la detección. Trinh et al. [Trinh et al., 2025] reportaron mejoras del 12,3% en F1 con arquitecturas multi-agente. Y Kolli et al. [Kolli et al., 2025] validaron que la activación condicional por *fallback* es una estrategia efectiva.

Sin embargo, ninguno de estos sistemas ha sido aplicado al dominio financiero en español, ni integra fuentes institucionales latinoamericanas. Este proyecto llena ese vacío al adaptar las arquitecturas validadas en la literatura al contexto regulatorio financiero colombiano.

2. Justificación práctica

Colombia cuenta con un ecosistema de verificación de hechos activo (Colombia-Check, AFP Factual) pero manual, con capacidad limitada frente al volumen creciente de desinformación. Un sistema automatizado de verificación podría servir como herramienta de apoyo para verificadores humanos, entidades financieras y reguladores, permitiendo priorizar las noticias que requieren verificación urgente.

Adicionalmente, el benchmark de evaluación que se construirá constituye un recurso reutilizable: cualquier investigador o entidad podrá evaluar nuevos modelos o herramientas de verificación contra este conjunto de datos, extendiendo el impacto del proyecto más allá de su alcance inmediato.

3. Justificación social

La desinformación financiera afecta desproporcionadamente a poblaciones con menor alfabetización financiera y mediática. Un sistema que pueda identificar y explicar por qué una noticia es falsa contribuye a la protección del ciudadano y a la estabilidad del sistema financiero colombiano. El enfoque de explicabilidad adoptado en este proyecto (donde cada veredicto incluye las fuentes consultadas y el razonamiento del agente) es especialmente relevante para generar confianza en la herramienta.

4. Alcance

El proyecto se delimita al dominio de noticias financieras y bancarias colombianas en formato textual. No se abordan contenidos multimodales (imágenes, videos), ni se cubren otros países de la región (aunque la arquitectura es extensible). El sistema se evalúa como herramienta de apoyo a la verificación, no como reemplazo de verificadores humanos.

Objetivos

1. Objetivo general

Diseñar, implementar y evaluar un sistema híbrido de detección de desinformación financiera en español colombiano que integre clasificación mediante modelos de lenguaje de gran escala y validación agéntica de fuentes institucionales, midiendo su mejora en precisión y explicabilidad frente a modelos de lenguaje utilizados de forma independiente.

2. Objetivos específicos

- Construir un benchmark de evaluación de desinformación financiera colombiana compuesto por 800 a 1.000 noticias etiquetadas en tres categorías (verdadera, dudosa, falsa), recopiladas de verificadores certificados por la IFCN y medios económicos de referencia.
- Evaluar y comparar el desempeño de al menos tres modelos de lenguaje de gran escala como clasificadores de desinformación financiera en configuraciones zero-shot, few-shot y chain-of-thought, utilizando métricas de F1, precisión y recall.
- Diseñar e implementar un agente verificador de fuentes basado en el framework ReAct, equipado con herramientas de consulta a la Superintendencia Financiera de Colombia, el Banco de la República, el DANE y ColombiaCheck, que se active condicionalmente cuando el clasificador presente confianza inferior a un umbral definido.
- Integrar el clasificador y el agente verificador mediante un orquestador basado en LangGraph, y evaluar la mejora del sistema híbrido frente al clasificador independiente en métricas de precisión, recall, F1 y explicabilidad.

2. Objetivos específicos

Metodología

El diseño metodológico se estructura en cuatro fases secuenciales, cada una con criterios de validez, instrumentos y entregables definidos.

1. Aspectos principales de la metodología

El proyecto adopta un enfoque experimental cuantitativo con diseño cuasi-experimental, donde la variable independiente es la configuración del sistema (LLM solo vs. sistema híbrido LLM + agente) y las variables dependientes son las métricas de desempeño (F1, precisión, recall) y explicabilidad. Se utilizan múltiples modelos de lenguaje y configuraciones de prompting para controlar el efecto del modelo específico sobre los resultados.

Hipótesis: El sistema híbrido que combina un LLM clasificador con un agente verificador de fuentes institucionales colombianas alcanza un F1 macro significativamente superior al LLM utilizado de forma independiente en la detección de desinformación financiera colombiana.

2. Método de investigación

2.1. Datos

Universo y muestra

El universo de estudio comprende las noticias financieras y bancarias que circulan en medios digitales colombianos y que han sido objeto de verificación por organizaciones certificadas por la IFCN, así como noticias publicadas por medios económicos de referencia. La muestra objetivo es de 800 a 1.000 noticias, distribuidas en tres clases:

- **Verdaderas (300–400):** Noticias publicadas por medios con credibilidad editorial verificable (Portafolio, La República, sección económica de El Tiempo) y comunicados oficiales del Banco de la República, Superintendencia Financiera y DANE.
- **Falsas (300–400):** Noticias verificadas y clasificadas como falsas o engañosas por ColombiaCheck o AFP Factual Colombia, filtradas al dominio financiero y bancario.

3. Proceso metodológico

- **Dudosas (200–300):** Noticias clasificadas por los verificadores como “parcialmente cierta”, “sin evidencia suficiente” o “descontextualizada”, así como contenido viral financiero sin verificación institucional.

Adquisición

La recolección se realiza mediante tres mecanismos:

1. **Scraping automatizado:** Desarrollo de scrapers con Scrapy y Trafilatura para extracción de ColombiaCheck (verificaciones del dominio financiero), Portafolio, La República y comunicados oficiales. Se respetan los archivos robots.txt y términos de servicio.
2. **Datasets públicos existentes:** Integración de corpus públicos en español (IberLEF, FakeDeS) con re-etiquetado según la taxonomía propuesta cuando sea pertinente.
3. **Pipeline automatizado:** Configuración de GitHub Actions para recolección periódica y actualización del corpus.

Cada noticia incluye los siguientes metadatos: URL original, fuente, fecha de publicación, categoría temática financiera, enlace a la verificación del fact-checker (cuando aplique), y texto completo.

Etiquetado y validación

Las noticias verdaderas y falsas reciben su etiqueta de la fuente primaria (medio de referencia o fact-checker IFCN). Las noticias dudosas requieren anotación manual por al menos dos anotadores independientes, con medición de acuerdo inter-anotador mediante el coeficiente Kappa de Cohen (meta: $\kappa \geq 0,70$, acuerdo sustancial). Las discrepancias se resuelven por consenso con un tercer anotador.

Se implementan controles de calidad: detección de duplicados mediante similitud de n-gramas (umbral $> 0,85$), validación de balance por clase, y anonimización de información personal identificable.

3. Proceso metodológico

3.1. Fase 1: Construcción del benchmark (Junio–Julio 2026)

Recolección, etiquetado y validación del corpus. Redacción del marco teórico y estado del arte.

3.2. Fase 2: Evaluación del LLM como clasificador (Agosto–Septiembre 2026)

Se evalúan al menos tres LLMs en el benchmark construido, en cuatro configuraciones progresivas:

1. **Nivel 1 – Zero-shot genérico:** Prompt básico sin contexto de dominio. Constituye el *baseline* ingenuo (equivalente a “pegar la noticia en ChatGPT”).
2. **Nivel 2 – Zero-shot con prompt de dominio:** Prompt especializado con rol de experto financiero colombiano, instrucciones detalladas sobre indicadores de veracidad y formato de salida estructurado con puntuación de confianza.
3. **Nivel 3 – Few-shot con ejemplos del corpus:** Se proporcionan 3–5 ejemplos reales de cada clase, seleccionados estratégicamente del dominio financiero colombiano.
4. **Nivel 4 – Few-shot con chain-of-thought:** Se solicita al modelo razonar paso a paso: ¿la fuente citada existe?, ¿el dato es verificable?, ¿el lenguaje es neutral o sensacionalista?, ¿menciona entidades regulatorias reales?

Los modelos candidatos incluyen: Gemini Pro/Flash (Google), GPT-4o-mini (OpenAI), y un modelo de código abierto ejecutable en Google Colab (Llama 3.1 8B o Mistral 7B con cuantización).

3.3. Fase 3: Implementación del agente verificador (Octubre–Noviembre 2026)

Se implementa el agente basado en ReAct [Yao et al., 2023] con las siguientes herramientas de dominio:

- `consultar_superfinanciera`: Consulta de comunicados y alertas de la Superintendencia Financiera de Colombia.
- `verificar_banco_republica`: Consulta de comunicados oficiales y datos del Banco de la República.
- `buscar_colombiacheck`: Búsqueda en la base de datos de verificaciones de ColombiaCheck.
- `buscar_medios_economicos`: Verificación en Portafolio y La República.
- `validar_fuente_citada`: Comprobación de la existencia de la fuente citada en la noticia.

El agente se integra con el clasificador mediante LangGraph. El flujo de decisión es:

3. Proceso metodológico

1. La noticia ingresa al sistema.
2. El LLM clasificador emite predicción (verdadera/dudosa/falsa) con puntuación de confianza.
3. Si la confianza es $\geq 0,80$: se acepta la clasificación del modelo.
4. Si la confianza es $< 0,80$: se activa el agente verificador.
5. El agente consulta las fuentes institucionales y emite veredicto con justificación.
6. El sistema retorna el veredicto final con las fuentes consultadas y el razonamiento.

Se experimenta con múltiples umbrales (0.70, 0.75, 0.80, 0.85) para determinar el valor óptimo.

3.4. Fase 4: Evaluación comparativa y redacción (Diciembre 2026–Enero 2027)

La evaluación compara cinco configuraciones (los cuatro niveles del clasificador más el sistema híbrido completo) utilizando las siguientes métricas:

Métricas primarias:

- F1 macro: promedio de F1 por clase, métrica principal por su robustez ante desbalance.
- Precisión y recall por clase: desagregados para verdadera, dudosa y falsa.
- Matriz de confusión: visualización de patrones de error.

Métricas del sistema híbrido:

- Tasa de activación del agente: porcentaje de noticias que activan la verificación.
- Mejora marginal: ganancia de precisión cuando el agente interviene.
- Latencia: tiempo promedio de procesamiento por noticia.
- Cobertura de evidencia: porcentaje de casos donde el agente encontró evidencia relevante.

Métricas de explicabilidad:

- Fidelidad: consistencia entre la explicación del agente y el veredicto emitido.
- Trazabilidad: porcentaje de veredictos con fuentes verificables citadas.

Significancia estadística: Se aplica la prueba de McNemar para determinar si las diferencias entre el clasificador solo y el sistema híbrido son estadísticamente significativas ($p < 0,05$).

Cronograma

El proyecto se ejecuta en un periodo de ocho meses, desde junio de 2026 hasta enero de 2027, distribuido en cuatro fases. La Tabla 7.1 presenta el cronograma detallado por actividades.

Tabla 7.1: Cronograma de actividades del proyecto

Actividad	Jun	Jul	Ago	Sep	Oct	Nov	Dic	Ene
Fase 1: Corpus y Estado del Arte								
Configuración de scrapers y recolección piloto								
Recolección masiva y pipeline automatizado								
Etiquetado y validación inter-anotador								
Redacción de marco teórico y estado del arte								
Fase 2: Clasificador LLM								
Implementación de prompts (zero-shot, few-shot, CoT)								
Evaluación comparativa de LLMs								
Análisis de errores y determinación de umbral								
Redacción del capítulo de metodología								
Fase 3: Agente Verificador								
Implementación de herramientas de dominio								
Configuración de LangGraph y flujo condicional								
Integración clasificador + agente								
Evaluación del sistema híbrido completo								
Fase 4: Evaluación y Redacción								
Evaluación final y pruebas de significancia								
Redacción de resultados y discusión								
Redacción de conclusiones y revisión final								
Preparación de sustentación								



UNIVERSIDAD
SERGIO ARBOLEDA

Presupuesto

El presupuesto del proyecto se estima considerando los recursos computacionales, las APIs de modelos de lenguaje, el recurso humano y los costos académicos. La Tabla 8.1 presenta el desglose.

Tabla 8.1: Presupuesto general del proyecto

Categoría	Investigador	Universidad	Total (COP)
Personal			
Horas investigador (640 h × \$25.000/h)	16.000.000	0	16.000.000
Anotadores corpus (2 × 40 h × \$20.000/h)	1.600.000	0	1.600.000
Infraestructura computacional			
Google Colab Pro (8 meses × \$50.000/mes)	400.000	0	400.000
APIs LLMs (Gemini, GPT-4o-mini)	600.000	0	600.000
Hardware			
Equipo de cómputo (existente, depreciación)	2.000.000	0	2.000.000
Software			
Herramientas de desarrollo (código abierto)	0	0	0
Costos académicos			
Matrícula maestría (estimado proporcional)	8.000.000	0	8.000.000
Total	28.600.000	0	28.600.000

Valores estimados en pesos colombianos (COP). El proyecto utiliza predominantemente herramientas de código abierto e infraestructura en la nube.

El proyecto se diseña intencionalmente para ejecutarse con infraestructura accesible: Google Colab para entrenamiento y experimentación, APIs comerciales con costos controlados, y herramientas de código abierto (LangGraph, Scrapy, Python). Esto garantiza la reproducibilidad y reduce las barreras de entrada para investigadores que deseen extender el trabajo.



UNIVERSIDAD
SERGIO ARBOLEDA

Resultados esperados

Los resultados esperados se organizan según las tres perspectivas solicitadas por el programa de Maestría en Inteligencia Artificial.

1. Generación de Nuevo Conocimiento

Tabla 9.1: Resultados o productos esperados de nuevo conocimiento.

Resultado o Producto esperado	Indicador	Beneficiario
Benchmark de evaluación de desinformación financiera colombiana (800–1.000 noticias etiquetadas)	Dataset publicado en repositorio abierto	Comunidad científica e investigadores en NLP en español
Sistema híbrido LLM-agente para verificación de hechos financieros	Prototipo funcional con código abierto	Verificadores de hechos y entidades financieras colombianas
Artículo científico con resultados experimentales	Artículo sometido a conferencia o revista indexada	Comunidad académica en IA y procesamiento de lenguaje natural
Herramientas de consulta para el ecosistema regulatorio financiero colombiano	Conjunto de tools reutilizables para agentes	Desarrolladores e investigadores en sistemas multi-agente

2. Fortalecimiento de la capacidad científica nacional

- **Formación de recurso humano:** Formación de un magíster en Inteligencia Artificial con competencias en procesamiento de lenguaje natural, sistemas multi-agente y verificación automatizada de hechos.
- **Colaboración interdisciplinaria:** El proyecto integra conocimientos de inteligencia artificial, lingüística computacional, regulación financiera y periodismo de verificación, fortaleciendo la capacidad de investigación interdisciplinaria de la Universidad Sergio Arboleda.
- **Infraestructura de investigación:** El benchmark de evaluación y el pipeline de recolección automatizada quedan disponibles como recursos para futuras investigaciones del grupo de investigación.

3. Apropiación social del conocimiento

- **Herramienta de apoyo a verificadores:** El sistema puede ser utilizado por organizaciones de fact-checking colombianas (ColombiaCheck, AFP Factual) como herramienta de priorización y pre-verificación de contenido financiero sospechoso.
- **Repositorio público:** El código fuente, el benchmark y la documentación se publicarán en un repositorio de GitHub bajo licencia abierta, permitiendo la replicación y extensión por parte de la comunidad.
- **Divulgación:** Presentación de resultados en la ExpoPosgrados ECEI y en al menos un evento académico nacional o internacional (candidatos: IberLEF, encuentro nacional de IA).
- **Impacto social:** Contribución a la protección del ciudadano colombiano frente a la desinformación financiera, particularmente en poblaciones con menor alfabetización financiera y mediática.

Anexos

4. Diagrama de arquitectura del sistema

El sistema híbrido propuesto se compone de tres capas principales:

1. **Capa de entrada (Frontend):** Interfaz donde el usuario ingresa la URL o el texto de la noticia financiera a verificar.
2. **Capa de clasificación (LLM):** Un modelo de lenguaje de gran escala clasifica la noticia en tres categorías (verdadera, dudosa, falsa) y emite una puntuación de confianza.
3. **Capa de verificación (Agente):** Cuando la confianza del clasificador es inferior al umbral definido, un agente inteligente basado en ReAct consulta fuentes institucionales colombianas y emite un veredicto fundamentado.

El flujo completo es orquestado por LangGraph mediante un grafo de estados con nodos condicionales.

5. Listado de fuentes institucionales del agente

- Superintendencia Financiera de Colombia (<https://www.superfinanciera.gov.co>)
- Banco de la República (<https://www.banrep.gov.co>)
- Departamento Administrativo Nacional de Estadística – DANE (<https://www.dane.gov.co>)
- ColombiaCheck (<https://colombiacheck.com>)
- Portafolio (<https://www.portafolio.co>)
- La República (<https://www.larepublica.co>)

5. Listado de fuentes institucionales del agente



UNIVERSIDAD
SERGIO ARBOLEDA

Bibliografía

- [Wu2,] Exclaim: An explainable cross-modal agentic system for misinformation detection with hierarchical retrieval, author=Wu, Yin and Zhang, Zhengxuan and Wang, Fuling and Luo, Yuyu and Xiong, Hui and Tang, Nan, journal=arXiv preprint arXiv:2504.06269, year=2024. 17, 21
- [Activa Research and WIN International, 2022] Activa Research and WIN International (2022). Fake news – desinformación en chile y latam. Technical report. Muestra de 6.049 participantes en 8 países latinoamericanos. 18
- [Brown et al., 2020] Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., et al. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33:1877–1901. 16
- [Cañete et al., 2020] Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., and Pérez, J. (2020). Spanish pre-trained bert model and evaluation data. In *Proceedings of the PML4DC Workshop at ICLR 2020*. 17
- [Conneau et al., 2020] Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., and Stoyanov, V. (2020). Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL 2020)*, pages 8440–8451. 17
- [Google DeepMind, 2024] Google DeepMind (2024). Gemini: A family of highly capable multimodal models. arXiv preprint arXiv:2312.11805. 15
- [Hoes et al., 2024] Hoes, E., Altay, S., and Bermeo, J. (2024). Using chatgpt to fight misinformation: Chatgpt nails 72 % of 12,000 verified claims. *Frontiers in Artificial Intelligence*. 13, 15, 19
- [Investigadores varios, 2025] Investigadores varios (2025). Explanatory factors for the dissemination and control of fake news in the Latin American context. *Humanities and Social Sciences Communications*, 12:741. Primer estudio de este tipo en América Latina, usando datos del Latinobarómetro 2023. 18
- [Kolli et al., 2025] Kolli, S., Rosenbaum, R., Cavelius, T., Strothe, L., Lata, A., and Diesner, J. (2025). Hybrid fact-checking that integrates knowledge graphs, large

-
- language models, and search-based retrieval agents improves interpretable claim verification. *arXiv preprint arXiv:2511.03217*. 17, 21
- [Lazer et al., 2018] Lazer, D. M. J., Baum, M. A., Benkler, Y., Berinsky, A. J., Greenhill, K. M., Menczer, F., Metzger, M. J., Nyhan, B., Pennycook, G., Rothschild, D., Schudson, M., Sloman, S. A., Sunstein, C. R., Thorson, E. A., Watts, D. J., and Zittrain, J. L. (2018). The science of fake news. *Science*, 359(6380):1094–1096. 15
- [Li et al., 2024] Li, X., Zhang, Y., and Malthouse, E. C. (2024). Large language model agent for fake news detection. In *Proceedings of the 27th European Conference on Artificial Intelligence (ECAI 2024)*, volume 392 of *Frontiers in Artificial Intelligence and Applications*, pages 2572–2579. IOS Press. 16, 21
- [Meta AI, 2024] Meta AI (2024). The llama 3 herd of models. *arXiv preprint arXiv:2407.21783*. 15
- [OpenAI, 2023] OpenAI (2023). Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*. 15
- [Oshikawa et al., 2020] Oshikawa, R., Qian, J., and Wang, W. Y. (2020). A survey on natural language processing for fake news detection. *arXiv preprint arXiv:1811.00770*. 13, 19
- [Sánchez Gálvez et al., 2024] Sánchez Gálvez, A. M., Javier Albores, F., Álvarez González, R., González Conde, S., and Sánchez Gálvez, S. (2024). A study on the detection of fake news in spanish. *International Journal of Combinatorial Optimization Problems and Informatics*, 15(2):85–94. 17
- [Trinh et al., 2025] Trinh, T., Nguyen, M., and Hy, T.-S. (2025). Towards robust fact-checking: A multi-agent system with advanced evidence retrieval. *arXiv preprint arXiv:2506.17878*. 17, 21
- [Vosoughi et al., 2018] Vosoughi, S., Roy, D., and Aral, S. (2018). The spread of true and false news online. *Science*, 359(6380):1146–1151. 15, 19
- [Wei et al., 2022] Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., and Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35:24824–24837. 16
- [World Economic Forum, 2024] World Economic Forum (2024). The global risks report 2024. Technical report, World Economic Forum, Geneva, Switzerland. 19
- [Xiong et al., 2025] Xiong, B. et al. (2025). Delphiagent: A trustworthy multi-agent verification framework for automated fact verification. *Information Processing & Management*, 62:104241. 17

- [Yao et al., 2023] Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., and Cao, Y. (2023). React: Synergizing reasoning and acting in language models. arXiv preprint arXiv:2210.03629. 16, 27